医疗器械财报问答知识库 • 结论

12 家 A 股医疗器械公司 × 4 份定期报告 = 48 份 PDF，自建「抓取 → 解析 → 分块 → BM25 + 向量双索引 → RRF 融合 → 带引用问答页面」全流程，10 道题逐题评测。

结论：单公司事实题（Q1/Q2/Q9）三个 mode 全答对；跨公司全景题不是模型答不好， 是 12 家的数塞不进 8 块里。扇出把覆盖公司数从 3.6 抬到 7.6 家/题，但全景题要 12 家 全对，故无一道「全中」——改善的是覆盖面，不是对错。

1. 关键设计（都是先测再定）

- **BM25 只索引正文**，不索引含公司全称的 `embed_text`——全称每块都出现、idf 被拉平， 问「迈瑞 2025 营业收入」排第一的是 2024 年报封面；换口径后正确的页回到第 1。
- **公司名当元数据过滤器，不当检索词**：财报表格里不重复公司全称，点名迈瑞的题 top-8 里有 5 块是别家；定向后全部命中。
- **报告期 + 年份双重过滤**：年度/半年度章节名完全一样，且 2024 年报 `kind` 也是 「年度」，会被当成 2025 的数用。报告期纯度 25%~75% → 100%。
- **全景题逐家扇出**：单轮 top-k 最多 8 块，改成每家各取、轮转合并。

2. 消融：每层各值多少分（`bench_retrieval_ablation.py`，不调模型）

元数据过滤（topk=8）：无过滤 5/89 → +报告期 13/89 → +年份 **15/89**，不动索引与模型 就翻三倍，性价比最高。各机制（**只有同一 topk 内的数才可比**）：

topk	bm25	vec	mix	panorama
8	15/89	13/89	**20/89**	—
24	32/89	20/89	34/89	**53/89**
48	**42/89**	—	35/89	—

两处对我不利的读数。① **混合检索的优势是「小预算优势」**：topk=48 时纯 BM25 的 42 反超 mix 的 35。② **我改掉过一个错数**：最早手测得扇出 40/89，据此写「预算加到 48 就反超扇出」。补测发现那 40 是假的——当时用 `Searcher(need_vec=False)` 省掉向量加载， 而扇出的底是 `mix`，向量一缺就**静默退化成纯 BM25**（缺失时 panorama 40、mix 32， 与 bm25 的 32 完全相同；加载后 panorama **53**、mix 34）。所以「反超」不成立。

3. 10 题结果（`out/检索评测.md` 逐题可复核）

「数值全中」**bm25 3/8、mix 2/8、panorama 3/8**（分母 8 = 有数值基准的题；Q6 语义题、 Q10 跨表推理无基准，不参与）。引用合法性三个 mode 全 100%。

- **单公司题已可靠**：Q1 表内三数、Q2 增速、Q9 口径陷阱全中；唯一例外 Q7 只 2/4 （细分业务收入写在正文段落里、单位不一致）。
- **全景题只有部分覆盖，扇出在四题上全面领先**：

	Q3	Q4	Q5	Q8
bm25	2/7	0/6	1/5	4/10
mix	2/7	2/6	1/5	3/10
panorama	**5/7**	**3/6**	**4/5**	**7/10**

4. 三个发现

1. **表格的「词汇鸿沟」是真的，但没有代价——我为此连错两次。** 含全部 4 个原始数字的 那块，列头「本期比上年同期增减(%)」被 PDF 折行切成两行，「同比」二字连不起来，BM25 名次 655→415→215→**22**，vec 排 2、mix 排 4。我据此写下「只用 BM25 答不出」，**实测 三个 mode 的 Q2 全部全中**：p.15 正文有「营业总收入…**同比增长33.98%**」，BM25 排第 1。 **「某个块没召回」≠「这题答不出」。**
2. **扇出改善覆盖面，不改善「全中」题数**（3.6→7.6 家/题，全中仍 3/8）；混合检索也不 普遍更好，Q9 上 BM25 全中 4/4、mix 只 2/4。
3. **检索失败会被模型包装成「财报未披露」**：强制弃答防住了编数（对的），但检索失败时 它变成一句自信的「未披露」，**把检索问题伪装成事实**。反过来只看召回就断言答不出， 同样会错（见发现 1）。

5. 局限

- 「数值命中」= 真值数字出现在答案里的比例，**只是疑似对**，不是准确率；每条附原文待复核。
- 判分基准只覆盖 12 家的营收/归母/扣非，Q6/Q10 无基准；全景题要求 12 家全对，标准偏严。
- 数值覆盖口径下块越多越易命中，**跨 topk 不可比**；`topk=48` 受 `per_company=3` 约束， 多公司题实际只回 29~36 块。
- 语料仅 12 家 / 48 份，扇出在公司数更多时未测；全程同一个模型，无多模型对照。

交付：`README.md`（复现与踩坑）、`src/`（24 个脚本）、`out/检索评测.md`（逐题召回块、 哪一路找到、失败原因）、`docs/shots/`（截图 9 张）、本文件。